

METODOLOGIA DE BOX & JENKINS

O objetivo da metodologia Box & Jenkins é determinar os três componentes dos modelos estruturais de séries temporais:



p

parâmetros auto-regressivos,



d

processos de
diferenciação (ordem
de integração)



q

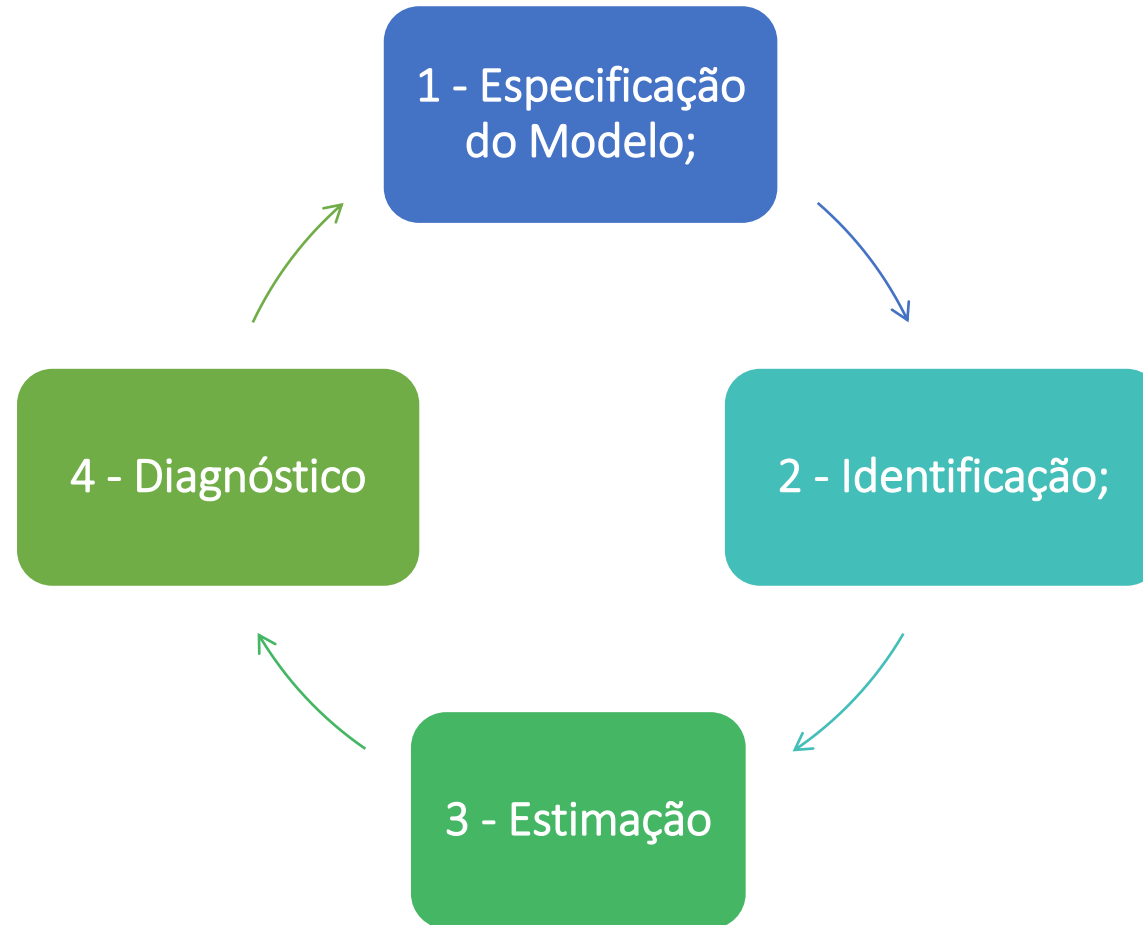
parâmetros de
médias móveis

ARIMA (p, d, q)

Por exemplo, um ARIMA (1, 2, 0) possui **um** parâmetro auto-regressivo, **duas** diferenciações desde a série original (integrado de ordem dois) e **nenhum** parâmetro de médias móveis.

METODOLOGIA DE BOX AND JENKINGS

Lógica da proposta de Box & Jenkins:



1 – Especificação do Modelo

Esse passo já considera diferenciar a série de dados até deixá-la estacionária:

Primeira diferença:

$$\Delta Y_t = Y_t - Y_{t-1} \quad \rightarrow I(1) : \text{Integrada de ordem 1} \quad \rightarrow d = 1$$


Segunda diferença:

$$\Delta(\Delta Y_t) = \Delta Y_t - \Delta Y_{t-1} \quad \rightarrow I(2) : \text{Integrada de ordem 2} \quad \rightarrow d = 2$$

Por meio da FAC e FACP especifica-se se o modelo possui termos autorregressivos AR e de médias móveis MA.

Exemplo:
ARIMA(11, 1, 17)

Considerando que a série foi diferenciada uma vez para se tornar estacionária



2 – Identificação do Modelo

Considerando o exemplo do ARIMA (11, 1 , 17), devemos identificar as ordens p e q para o melhor modelo.

Os modelos a considerar são:

ARIMA(1, 1 , 1)

ARIMA(1, 1 , 2)

...

ARIMA(1, 1 , 17)

ARIMA(2, 1 , 1)

ARIMA(2, 1 , 2)

...

ARIMA(2, 1 , 17)

ARIMA(3, 1 , 1)

... ...

ARIMA(17, 1 , 17)

Calcula-se os Critérios de Informação BIC e AIC para todos modelos e o modelo com menor valor indica a ordem do melhor modelo.

3 – Estimação

Identificado a ordem do melhor modelo, passamos então a estima-lo e delineamos sua forma funcional.

Por exemplo se o melhor modelo foi um ARIMA (2,1,2) sua forma funcional é:

$$\Delta Y_t = c + \underbrace{\phi_1 \Delta Y_{t-1} + \phi_2 \Delta Y_{t-2}}_{\text{AR(1)}} + \underbrace{\theta_1 \Delta \varepsilon_{t-1} + \theta_2 \Delta \varepsilon_{t-2}}_{\text{MA(1)}} + e$$

AR(1)

MA(1)

AR(2)

MA(2)

ARMA(2,1)

ARMA(2,2)

4 – Diagnóstico dos Resíduos

- . Autocorrelação: Teste LM e Ljung Box
- . Normalidade: Jarque-Bera, Histogramas e Kernel
- . Ruído Branco: Portmanteau
- . Heterocedasticidade: ARCH- LM

O teste ARCH-LM serve para testar presença de heterocedasticidade no modelo.

Considere:

$$\hat{\varepsilon}_t = \beta_1 \hat{\varepsilon}_t^2 + \beta_2 \hat{\varepsilon}_{t-1}^2 + \dots + \beta_h \hat{\varepsilon}_{t-h}^2 + \mu_t$$


Teste:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_h = 0$$

$$H_1: \beta_1 \neq 0 \text{ ou } \beta_2 \neq 0 \dots \beta_h \neq 0$$

$$ARCH - LM_h = R^2 \xrightarrow{d} \chi^2_h$$

H_0 : não há heterocedasticidade no modelo.



Se o **valor-p** > 0,05 não rejeitaremos a hipótese nula: **não há heterocedasticidade**

Se o **valor-p** < 0,05 rejeitaremos a hipótese nula: **há heterocedasticidade**

```
remove.packages("readxl")
install.packages("readxl", dependencies = T)
remove.packages("aTSA")
install.packages("aTSA", dependencies = T)
remove.packages("tseries")
install.packages("tseries", dependencies = T)
```

```
library(readxl)
library(aTSA)
library(tseries)
library("urca")
```

```
BITCOIN <- na.omit(read_excel("C:/Econometria/Bitcoin.xls"))
```

```
Bitcoin <- ts(log(BITCOIN$close), start = 2014, frequency = 365)
```

```
plot(Bitcoin, type="l", main="Logaritmos do Preço do Bitcoin", ylab="Log Preço", xlab="Data", col="Blue")
grid(col = "black", lty = "dotted")
```

Logaritmos do Preço do Bitcoin



```
acf(log(BITCOIN$close),lend=2, lwd=5,col="darkblue",main= "Função Autocorrelação - FAC")
axis(1,tck = 1, col = "lightgrey", lty = "dotted")
```

```
pacf(log(BITCOIN$close),lend=60, lwd=5,col="darkblue",main= "Função Autocorrelação Parcial - FACP")
axis(1,tck = 1, col = "lightgrey", lty = "dotted")
```

```
#Teste ADF
ur.df(Bitcoin, "none", lags = 1)
```

```
#Teste Philips-Perron
pp.test(Bitcoin)
```

```
#Teste KPSS
kpss.test(Bitcoin)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none

```
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.23806 -0.01356  0.00055  0.01638  0.22302
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
z.lag.1    0.0001711  0.0001344   1.273   0.203
z.diff.lag 0.0025478  0.0239236   0.106   0.915
```

```
Residual standard error: 0.03953 on 1747 degrees of freedom
Multiple R-squared:  0.0009409, Adjusted R-squared:  -0.0002028
F-statistic: 0.8227 on 2 and 1747 DF,  p-value: 0.4394
```

Value of test-statistic is: 1.2735

```
Critical values for test statistics:
    1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

Phillips-Perron Unit Root Test

data: Bitcoin


Dickey-Fuller Z(alpha) = -4.91, Truncation lag parameter = 8, p-value = 0.8359
alternative hypothesis: stationary

KPSS Test for Level Stationarity

data: Bitcoin

KPSS Level = 13.825, Truncation lag parameter = 9, p-value = 0.01


Primeira Diferença dos Logs do Bitcoin - LogReturn




```
acf(IntOrdem1, lend=2, lwd=5, col="darkblue", main= "Função Autocorrelação - FAC")
axis(1, tck = 1, col = "lightgrey", lty = "dotted")
```

```
pacf(IntOrdem1, lend=60, lwd=5, col="darkblue", main= "Função Autocorrelação Parcial - FACP")
axis(1, tck = 1, col = "lightgrey", lty = "dotted")
```

Função Autocorrelação - FAC



Função Autocorrelação Parcial - FACP



```
AR1 <- arima(IntegradaOrdem1, order = c(1,1,0))
```

```
AR1
```

```
call:
```

```
arima(x = IntegradaOrdem1, order = c(1, 1, 0))
```

```
Coefficients:
```

```
      ar1
```

```
    -0.4753
```

```
s.e.    0.0210
```

```
sigma^2 estimated as 0.002409:  log likelihood = 2789.94,  aic = -5575.89
```

$$\Delta Y_t = -0.4753 \Delta Y_{t-1} + e$$

#Previsões


```
predict(AR1,15)
```

```
library(forecast)  
forecast(AR1,15)
```

```
plot(forecast(AR1,5), type="o", xlim=c(2018.75,2018.85), ylim=c(-0.03,0.06))  
grid(col = "black", lty = "dotted")
```

sãojudas

Forecasts from ARIMA(1,1,0)




```
> predict(AR1,15)
$pred
Time Series:
Start = c(2018, 291)
End = c(2018, 305)
Frequency = 365
 [1] -0.004158340 -0.005920396 -0.005082933 -0.005480959 -0.005291787 -0.005381696 -0.005338964 -0.005359274
 [9] -0.005349621 -0.005354209 -0.005352028 -0.005353065 -0.005352572 -0.005352806 -0.005352695

$se
Time Series:
Start = c(2018, 291)
End = c(2018, 305)
Frequency = 365
 [1] 0.04908621 0.05543342 0.06656120 0.07367063 0.08117124 0.08758117 0.09375332 0.09945346 0.10488468
[10] 0.11002980 0.11495320 0.11967041 0.12421035 0.12858929 0.13282432
```

ARCH heteroscedasticity test for residuals
alternative: heteroscedastic



Portmanteau-Q test:

	order	PQ	p.value
[1,]	4	221	0
[2,]	8	271	0
[3,]	12	291	0
[4,]	16	326	0
[5,]	20	348	0
[6,]	24	355	0

Lagrange-Multiplier test:

	order	LM	p.value
[1,]	4	1570	0
[2,]	8	748	0
[3,]	12	490	0
[4,]	16	352	0
[5,]	20	227	0
[6,]	24	227	0

arch.test(object, output = TRUE)



#Modelando a Variância

```
residuos <- AR1$residuals  
plot(residuos, type="o", main="Resíduos do AR1")  
grid(col = "black", lty = "dotted")
```

#FAC e FACP dos Resíduos

```
acf(residuos, lend=2, lwd=5, col="darkblue", main="Função Autocorrelação - FAC")  
axis(1, tck = 1, col = "lightgrey", lty = "dotted")
```

```
pacf(residuos, lend=60, lwd=5, col="darkblue", main="Função Autocorrelação Parcial - FACP")  
axis(1, tck = 1, col = "lightgrey", lty = "dotted")
```

```
GARCH202=garch(residuos, c(20,2), trace=F)
```

